Studying the Human Mind with AI

From Behavioral Analysis to Role Simulation

从行为分析到角色模拟 · 讲座讲义与配套阅读指南

Shiyu Hu

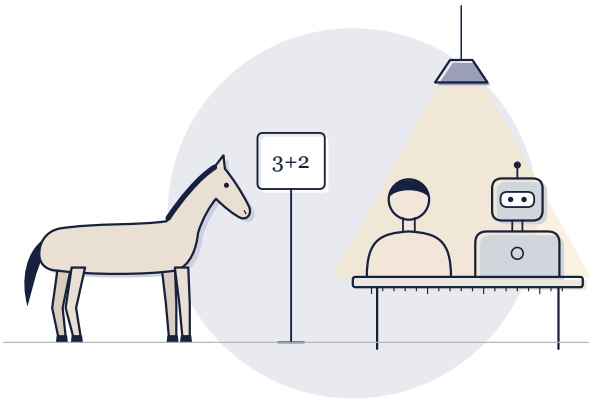
在线版：

https://github.com/huuuuusy/studying-the-mind-with-ai

开始所需的一切都在这份讲义里；访问 GitHub 很慢或无法访问时也能用。

扫码访问仓库

你听过讲座 *Studying the Human Mind with AI: From Behavioral Analysis to Role Simulation*（用 AI 研究人的心智：从行为分析到角色模拟），或者有人把这个链接发给了你。这一页只要五分钟，说明讲座讲了什么、这个仓库怎么组织，以及接下来去哪里。



一个问题

它看起来很有能力，我们怎么知道它真的具备这种能力？

2026 年 9 月，美国政府要求各机构不再说“人工智能”（artificial intelligence），改说“超级智能”（super intelligence），理由是这项技术“不只是在模仿或自动化人的智能”（fact sheet[1]；行政令[2]）。改了名字，智能是什么依然没有说清。就连最有名的超级智能定义，“在几乎每个领域都远比最聪明的人脑更聪明的智能”（Bostrom, 1998，原文[3]），也是拿人来衡量的。图灵在 1950 年就绕开了定义：他把“机器能思考吗”换成了一个拿人来比的测试，即图灵测试（doi[4]）。讲座开场放的就是最近一次这种测试里真实的一局：评判者把 AI 当成了人（卡片）。在所有对局里，被要求扮演一个害羞年轻人的 GPT-4.5 有 73% 的时候被选成真人；没有这个人设，只有 36%。它骗过了评判者，这说明的是我们怎样判断，不是它会思考。这个测试让我们了解 AI，也让我们了解自己的判断。

心理学的处境一样：心智打不开，只能从行为去读，拿人来比。心理学是更老的学科，AI 是更年轻的学科，两者是天然的搭档，而 AI 一直在向心理学借东西：

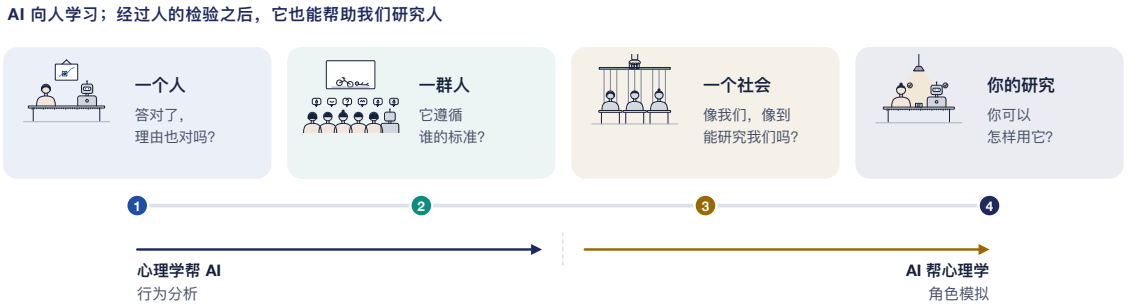
来自心理学	AI 借去之后
答对了，理由却可能不对：聪明的汉斯（1904）	捷径学习（2020；第 1 部分）
人怎样看：一种关于人类视觉的理论（Zhaoping，2023）	讲者团队的跟踪器（2024；第 1 部分）
怎样判断：Thurstone 的成对比较（1927）	ChatGPT 怎样学会人的偏好（2022；第 2 部分）
人怎样理解事件：Heider 和 Simmel 的移动图形（1944）	讲者团队工作中的按一群人打分（2024；第 2 部分）
怎样像一个人：大五人格（Goldberg，1990，doi[5]）	讲者团队带人设的虚拟学生（2025；第 3 部分）

方向也可以反过来：模型通过了检验之后，也能反过来帮助研究人。

讲座的一句话：**AI 向人学习；经过人的检验之后，它也能帮助我们研究人。**

[1] https://www.whitehouse.gov/fact-sheets/2026/09/fact-sheet-president-donald-j-trump-inaugurates-the-era-of-super-int
[2] https://www.whitehouse.gov/presidential-actions/2026/09/inaugurating-the-era-of-super-intelligence/
[3] https://nickbostrom.com/superintelligence
[4] https://doi.org/10.1093/mind/lix.236.433

讲座的四个部分



四个问题，一个比一个大：一个人、一群人、一个社会，再到你自己的研究。走到一半，方向反了过来：前半程是心理学帮我们检验 AI（行为分析，第 1–2 部分），后半程是 AI 帮我们研究人（角色模拟，第 3–4 部分）。

部分	问题	讲座的回答	导读
1 · 一个人：机器旁边的人	答对了，理由也对吗?	还没有：分数相近，错误不同。要检验理由，就**比错误，不只比分数。**	第 1 部分
2 · 一群人：人作为答案	它遵循谁的标准?	一群人，而不是一个人。要检验标准，就**拿一群人比，不拿一个人比。**	第 2 部分
3 · 一个社会：我们造出来的人	它像我们，像到能研究我们吗?	用来预演一项研究，不能取代研究里的人。要检验模拟，就**拿真实的人比。**	第 3 部分
4 · 在你自己的研究里用 AI	你可以怎样用它?	**先检验，再使用**：分析数据时，拿新的人来测，再只用一个线索试试；用你的标签做测量时，保留每一个评分者，他们的一致程度就是上限；模拟人时，看整个分布，也跨时间检验。	第 4 部分



讲座第 *46* 页：一页看完整场讲座。

加粗的这几个检验，都是心理学本来就有的。每一次检验也让我们了解人：我们怎样看、怎样理解事件、怎样在一起行动。一个关于 AI 的问题，一次次变成了关于我们自己的发现。

每部分的导读都有相同的几节：

- 讲座里讲了什么，通常按讲座的顺序：心理学早就知道的，AI 领域的经典工作，以及讲者团队做了什么；

- 背后的问题；
- **反过来，对心理学有什么用**；
- **五篇重点必读**：每篇做了什么、发现了什么、对这一部分意味着什么、没有表明什么，每篇另有一张一页纸的卡片；
- **它们之间的关系**；
- **更大的版图**：这部分所有核实过的参考文献；
- 讲座里讲者团队自己的研究（只列公开版本）；
- 用到的术语；
- 怎样和 AI 研究者一起做。

为什么是现在

讲座收尾时讲了讲者看到的两件事，以及讲者现在会怎样做研究（“为什么心理学和人文学科现在更重要”）。

- **速度，和核查。**今年数学界有两则新闻。7 月，Claude 找到了一个反例，推翻了一个 87 年的猜想，即三维及以上的雅可比猜想（T. Tao，博客[6]）。10 月，OpenAI 声称在几百个开放问题上有了结果（github.com/openai/math[7]），其中三篇论文第二天就撤回了（Retraction Watch[8]）。今年早些时候，一位顶尖数学家说，一份 AI 的证明可以算博士论文里像样的一章（W. T. Gowers，博客[9]）。所以在部分领域，AI 已经能像博士生那样工作，有时甚至像专家。可连领域里的领军人物也意见不一：图灵奖得主 Yann LeCun 认为，只靠文本训练，永远到不了人类水平的智能（G. Snyder，*Newsweek*，2025）。每个说法都还需要核查。
- **造东西便宜了，判断稀缺了。**AI 主要会议之一 ICLR 的投稿，2017 年是 490 篇，2026 年是 19,525 篇，2027 年已有大约 62,000 篇投稿，还没有审稿。ICLR 2026 上，18,054 位审稿人写了 76,139 份审稿意见。程序主席写道，这样的规模“使得只靠人的判断来一致地标记和发现有问题的审稿意见成为不可能”（ICLR Blog[10]）。这些投稿，总得有人一篇篇读完。

讲者现在会这样做研究：

- **比模型活得久。**问问自己：如果模型再强十倍，这件事还重要吗？
- **让 AI 去做，你来判断。**把“做”交给它，把“判断”留给自己；初稿自己写。
- **找到你自己的交叉点。**从你的领域最擅长提出的问题出发，再把 AI 带进来。比如：和 AI 说话，是增加了人与人的接触，还是取代了它？

讲座的看法是：当造东西变得便宜，判断才是真正的工作，而这一直是心理学和人文学科的本职。

讲座怎样结束

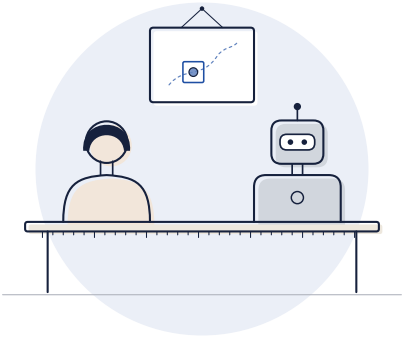
讲座就在这个看法上结束，最后一页指向这个仓库。问答时，讲座把回答归成五个，每个都指回讲出它的那几页：

1. **别只看分数。**答对了，理由也对吗？（第 1 部分，以及第 4 部分的分析。）
2. **拿一群人比。**它遵循谁的标准？（第 2 部分，以及第 4 部分的测量。）
3. **用来预演，不是取代。**它像我们，像到能研究我们吗？（第 3 部分，以及第 4 部分的模拟。）
4. **跨时间检验。**它还是它自己吗？（第 3 部分的虚拟学生。）
5. **判断是心理学的本职。**造东西变便宜之后，你受过的训练就是检验。

[6] https://terrytao.wordpress.com/2026/07/21/a-digestion-of-the-jacobian-conjecture-counterexample/
[7] https://github.com/openai/math
[8] https://retractionwatch.com/?p=136176
[9] https://gowers.wordpress.com/2026/05/08/a-recent-experience-with-chatgpt-5-5-pro/
[10] https://blog.iclr.cc/2026/03/31/a-retrospective-on-the-iclr-2026-review-process/

第 1 部分 · 一个人：机器旁边的人

答对了，理由也对吗？检验：**比错误，不只比分数。**

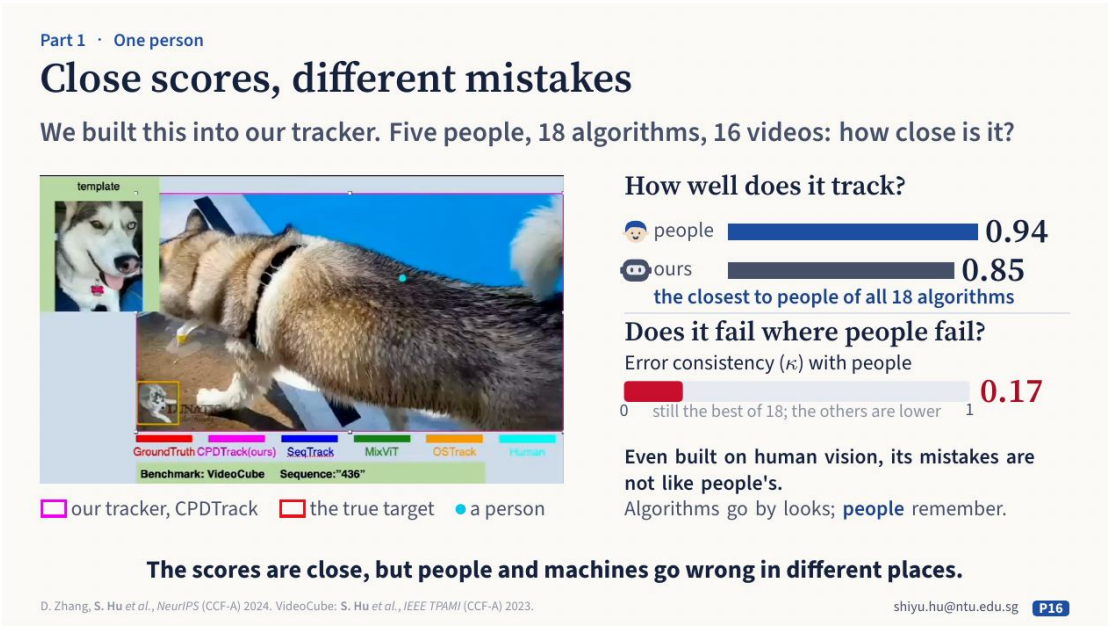


讲座里讲了什么

心理学早就知道的。聪明的汉斯是一匹看起来会数数的马。检验它时只改了一个条件：提问者知不知道答案？提问者知道时，汉斯的正确率是 98%；提问者不知道时，只有 8%。汉斯读的是提问者头部细微的、无意的动作，而不是在做算术。看起来像某种能力的行为，还不能证明它真的具备这种能力；受控比较才能。

AI 领域的经典工作。 AI 也有自己的聪明的汉斯。Sebastian Lapuschkin 等人发现，有个模型认马靠的是照片上的来源标签，而不是马本身。图宾根的 Robert Geirhos 等人发现，用 ImageNet（一个大型的带标签照片集）训练的网络，会把长着大象皮的猫认成大象：它们看纹理，人看形状。Geirhos 等人给这类问题起了个总的名字，叫捷径学习：在训练中管用的线索，却不是我们想要的能力。捷径也能得高分，所以要抓住它，就得比错误。Geirhos 等人用 Cohen's κ 衡量各自错在哪些图片上。讲座用了一个小例子：两个模型都答对 10 张图里的 7 张。一个和人错在同样的三张上（$\kappa = 1.00$），另一个只有一张相同（$\kappa = 0.05$）。分数一样，只有错误能把它们分开。

讲者团队做了什么。以人为参照做跟踪。跟踪是指在一段视频里跟住同一个物体，即使它暂时看不见了。AI 的常规测试只是一个简单的例子：一小段连续的单镜头，模型只要在上一个位置附近搜索。团队用了一个更难的任务，它更像真实视频，时间和空间都不连续：镜头一切，目标消失，又在别的地方出现。在这个任务上，人比二十种跟踪算法做得都好。团队人机研究里的一段视频显示了差别所在：在一群长得很像的火烈鸟里，人一直跟着同一只；一个最先进的算法却跳到了另一只长得像的鸟上。人跟住的是原来的目标，算法依赖的是外观。然后，团队按人怎样把目标找回来，造了一个跟踪器 CPDTrack。它借用的理论认为，周边视觉负责“看向哪里”，中央视觉负责“看清是什么”：宽而粗的周边视觉决定往哪里看，窄而细的中央视觉确认那里是什么。五个人和 18 种算法跟踪了同样的 16 段视频。人得了 0.94，CPDTrack 得了 0.85，是 18 种算法里最接近人的。但它和人的错误一致性只有 0.17（0 表示偶然水平，1 表示错误完全相同），这已经是 18 种算法里最高的。即使借鉴了人类视觉，它犯的错也不像人：算法看长相，人记得是哪一个。



讲座第 *16* 页：分数相近，错误不同。

背后的问题

答对了，理由也对吗？还没有：分数相近，错误不同。分数告诉我们结果，过程才告诉我们人和机器错在哪里。把模型和人比较时，不仅要比各自错了多少，还要比错在**哪些**题上；还要把你怀疑的线索和你本来想考的线索放到冲突里。用心理学的话说，这就是受控比较。人类参照是人与人之间的分布范围，而不是 100% 的上限。

要检验理由，就比错误，不只比分数。

反过来，对心理学有什么用

这些检验也让我们更了解人；在这一部分，是关于人怎样看。但照人类视觉理论造出的模型，本身并不能检验这个理论。从跟踪器里拿掉一个部件，说明的是模型需要什么，而不是人怎样看。中央视觉和周边视觉的分工在人身上是否成立，要回到人身上去检验：例如遮住中央视觉或周边视觉，看同类的错误会不会增多。这仍是一个悬而未决的问题：模型的部件，会像人的一样出错吗？

重点必读

先读这五篇。下面每篇都说明做了什么、发现了什么、对这一部分的问题意味着什么，以及它没有表明什么；方法的细节和数据在哪里，见各自的卡片。

1. 长着大象皮的猫：用 ImageNet 训练的网络看纹理，人看形状

Geirhos et al., 2019, *ICLR*

做了什么。采用线索冲突设计，这是知觉研究判断观察者使用两种线索中哪一种的标准做法。风格迁移（一种用另一张图像的纹理重画一张图像的方法）让每张图像具有某一类别的形状和另一类别的纹理，人和网络对同一批图像分类。人类数据来自实验室心理物理学研究：九项实验，48,560 个试次，97 名观察者。

发现了什么。用 ImageNet（一个大型的带标签照片集）训练的网络强烈偏好纹理，而人依据形状做判断。同一种网络结构（ResNet-50，一种常用的图像网络）如果在纹理被替换掉的 *Stylized-ImageNet* 上训练，就会转而学到基于形状的表征，与人类行为更吻合，对图像失真也更稳健。

对这一部分意味着什么。这就是讲座里那只长着大象皮的猫，也是这一部分问题最直白的形式：把怀疑的线索和本来想考的线索放到冲突里，看哪一种胜出，对人和机器都是如此。答案还取决于训练数据，而不只取决于架构。

它没有表明什么。形状与纹理只是众多线索维度中的一个。人和模型可能在哪种线索胜出上一致，却仍然错在不同的图像上；第 2 篇衡量的正是这一点。

2. 分数相近，错误不同：错误一致性

Geirhos, Meding & Wichmann, 2020, *NeurIPS*

做了什么。对每个试次，记录每个决策者是对还是错，再看两者在同一批试次上一起出错有多频繁，并和偶然水平比较：按两者各自的准确率，纯属偶然时会有多少次一起出错。这个指标就是用在对错上的 Cohen's κ，一个来自心理测量的统计量，可用于模型与模型、人与人、模型与人之间的比较。

发现了什么。在物体识别上，任何架构的网络彼此之间都高度一致，但它们与人类观察者的一致性只略高于偶然水平：在一批图片上，人与人之间是 0.33，网络与人之间只有 0.07。CORnet-S 是一个模拟大脑物体识别通路的模型，内部有把信号送回去的回路（循环模型）；在这里，它的表现与信号只朝一个方向传的标准图像网络（前馈的 ResNet-50）基本相同。

对这一部分意味着什么。这正是这一部分检验的原样：比各自错在哪些题上，而不只比错了多少。它比第 1 篇更进一步，从哪种线索胜出，走到错误是否落在同样的图像上，并把“模型像人一样处理图像”变成一个可能失败的检验。

它没有表明什么。一致的错误是共享策略的必要条件，但不是充分条件；仅凭 κ 低也无法确定模型用的是哪条捷径。解读 κ 时要以人与人之间的一致性为参照，而不是以理想值 1 为参照。

3. 在错误的地方找到正确答案：聪明的汉斯式预测器

Lapuschkin et al., 2019, *Nature Communications*

做了什么。解释方法显示模型依赖了输入的哪些部分，论文提出的谱相关分析（Spectral Relevance Analysis，SpRAy）把大量输入上的解释图归并成组，这样看到的是整体的策略，而不只是单个案例。决定性的检验与 Oskar Pfungst 在 1904 年对聪明的汉斯所用的检验相同：去掉可疑的线索，看答案是否还在；再把它加到不该出现的地方，看答案是否跟着走。

发现了什么。一个在公开照片集 PASCAL VOC 2007 上训练的图像分类器（Fisher 向量分类器，一种深度学习之前的较老方法），靠一个来源标签识别马，这个标签出现在大约五分之一的马图像中。去掉标签，“马”的分类就消失了；把标签加到一张汽车图像上，这张图像的分类随之改变。

对这一部分意味着什么。这就是讲座里 AI 自己的聪明的汉斯，它的逻辑来自心理学：去掉线索的操纵就是一个控制条件。Geirhos 等人后来把这类问题统称为捷径学习。第 2 篇能显示模型与人不同；这篇则展示怎样确定模型实际用的是哪条线索。

它没有表明什么。解释图本身也是测量，需要单独的效度检验：它只说明模型看了哪里，而不说明为什么。正是去除与插入检验让结论令人信服。

4. 部分成功：稳健性差距在缩小，一致性差距没有

Geirhos et al., 2021, *NeurIPS*

做了什么。人接受了一批分布外数据集的测试，也就是和模型训练时见过的图像不一样的图像，例如加噪、风格化或只保留边缘的图像：90 名被试，共 85,120 个心理物理学试次。所选模型与用带标签照片训练的标准网络不同：训练它们去做的事不同，结构不同，学过的图像数量也不同（100 万到 10 亿张），每个模型都在准确率和图像层面的错误一致性上与人比较。

发现了什么。稳健性差距正在缩小：在大多数数据集上，最好的模型现在已超过人在短暂呈现条件下的表现。图像层面仍有相当大的一致性差距，大多数模型在错误上彼此一致。在许多情况下，当训练集扩大到原来的 10 到 1,000 倍时，与人的一致性会提高。

对这一部分意味着什么。讲座里没有展示。后来，最好的模型在准确率上赶上了人，错误却仍然和人不同。它说明为什么准确率和错误一致性必须分开报告：一个模型是否“更像人”，取决于你测的是哪一个。人类试次数据是公开的。

它没有表明什么。人类数据来自对单张图像的短暂呈现，因此描述的是快速识别，而不是人类视觉的全部。结果描述的是 2021 年测试的模型。

5. 看见了，却没有知觉到：BLINK

Fu et al., 2024, *ECCV*（BLINK）

做了什么。十四项经典计算机视觉任务，例如相对深度、视觉对应和伪造检测，被改写成 3,807 道包含一张或多张图像的多项选择题，交给多模态语言模型（既能看图像、也能读文字的聊天模型）回答。人在同样题目上的准确率作为基线；随机猜测提供第二个参照点。

发现了什么。人的平均准确率为 95.70%。当时最好的模型 GPT-4V 和 Gemini 分别为 51.26% 和 45.72%，只比随机猜测高 13.17 和 7.63 个百分点。专门的计算机视觉模型要好得多。

对这一部分意味着什么。这项研究讲座里没有展示，它把这一部分的问题从图像分类器带到如今大多数人使用的聊天式模型上：流利的回答可能掩盖薄弱的知觉。最后读它，看这个问题今天延伸到了哪里。

它没有表明什么。它只比较准确率，没有比较人和模型在哪些题目上出错，而这正是第 2 篇能补上的一步。结果描述的是 2024 年测试的模型；更新的模型应该重新测试。

它们之间的关系

这几篇文献贯穿着三条主线。

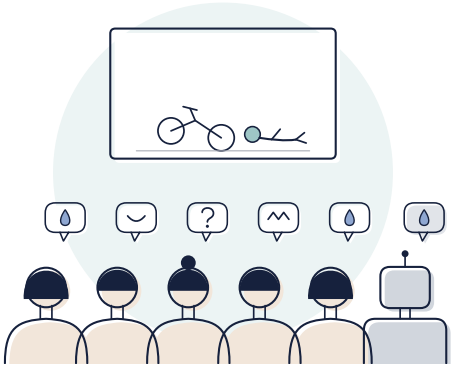
- **线索。** Pfungst 在 1904 年证明，聪明的汉斯是根据提问者头部细微的、无意的动作作答的：他去掉这个线索，答案就不灵了。Lapuschkin 等把同样的逻辑用到了分类器上。Geirhos 等（2020，*Shortcut learning in deep neural networks*，doi[11]）给出了一个总的名字：捷径是指在标准基准上管用、在更难的测试条件下却失灵的决策规则。这篇论文还指出，比较心理学、教育学和语言学里早就有类似的问题。
- **测量。**纹理偏好研究问的是两个线索里哪个胜出。错误一致性更进一步：人和模型是不是错在同样的图片上？它借用了心理测量中的统计量 Cohen’s κ。部分成功把两者都用到许多更新的模型上，并公开了人类的试次数据。
- **范围。**同样的比较如今已经用到了多模态语言模型上。BLINK 报告的是相对于人类基线的正确率；它还没有报告人和模型分别错在哪些题上，这正是自然的下一步。

悬而未决的问题。部分成功发现，模型在稳健性上已经追上甚至超过了人，错的却仍是不同的图片。一个模型是否“更像人”，取决于你测的是这两者中的哪一个，所以两者都要报告。

[11] https://doi.org/10.1038/s42256-020-00257-z

第 2 部分 · 一群人：人作为答案

它遵循谁的标准？检验：**拿一群人比，不拿一个人比。**



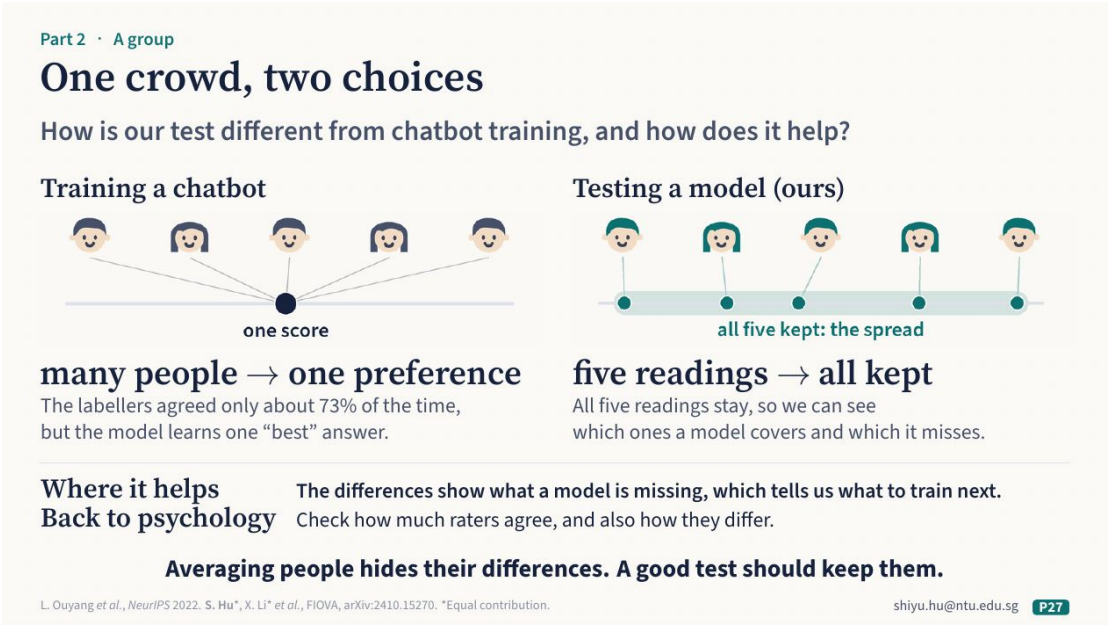
讲座里讲了什么

心理学早就知道的。给人看移动的图形，人会从中读出意图，而且每个人读得都不太一样：人不是一把尺子，而是一个分布。Thurstone 在 1927 年给出了办法，把很多人在一对对选项之间的选择，变成一把尺子。

AI 领域的经典工作。就在 ChatGPT 之前，这个来自心理学的想法教会了模型人们想要什么。2020 年，GPT-3 有 1750 亿个参数（模型在学习中调整的那些数值）。光靠规模，并不能给出人们喜欢的回答。2022 年 3 月的 InstructGPT 用上了基于人类反馈的强化学习（RLHF）：人给同一个提示词的几个回答排序，每个排序拆成一对一对的比较，这又是成对比较。用这些比较训练一个打分模型（“奖励模型”），聊天模型再学着在这个打分模型上拿高分。之后，人们更喜欢 13 亿参数的 InstructGPT 模型给出的回答，它比 GPT-3 小了一百多倍。同年 11 月的 ChatGPT 用的是同样的方法。可是这些排序出自大约 40 名标注员（也就是心理学说的评分者），他们彼此只有约 73% 的时候意见一致。它学到的，是谁的偏好？

讲者团队做了什么。以人为参照理解视频。连那些标注员也不总是一致，所以人的判断是一个分布，不是一个答案。AI 的常规测试却看不到这一点：它只要一句话，再和一个参考答案比，就像一个最终分数。所以团队把理解拆开，这和第 1 部分是同一个想法：不停在最终分数上，要看过程。发生了什么：从一个动作到整个故事。为什么：一步一步地问，这是 CausalStep。描述接近人：人答对 92.0%，最好的模型答对 85.2%。解释为什么却差得远：人答对 76.8%，最好的模型只有 39.8%，大约是人的一半。这是谁的解读：这是 FIOVA，五个人分别描述 3,002 段视频中的每一段。其中一段里，一个骑平衡车的孩子摔倒了。五个人都同意，他最后倒在了地上。这意味着什么，他们却说法不一：有一个人说他在装，有人说在哭，也有人说在笑。一个 AI 模型选了其中一种读法，“在哭”，并把它当成事实说了出来。所以五份描述全部保留，逐个事件地把模型和这一群人比较。这叫认知加权：五份描述越看重一个事件，它的权重越高；这说明的是观看者之间的一致，而不是这件事一定发生了。有一个模型的描述，覆盖了总权重的大约三分之一。

同一群人，两种选择。训练聊天机器人时，大家被平均成一种偏好，模型只学到一个“最好”的回答，尽管那些标注员只有约 73% 的时候意见一致。团队的测试保留全部五种解读，所以能看到模型覆盖了哪些、漏掉了哪些，也就知道下一步该训练什么。平均会藏起人与人的差异。好的测试应该把差异留下来。



讲座第 *27* 页：同一群人，两种选择。

背后的问题

它遵循谁的标准？一群人，而不是一个人。偏好训练最后只剩一个奖励分数；评测却可以把分布留下来。一个标签或一次多数投票，会掩盖人们之间有多大分歧。把模型当作又一位评分者：它和人的一致程度，是否达到人与人之间的一致程度？它保留了人们之间的分歧，还是把分歧抹平了？用心理学的话说，这就是评分者信度，而评分者之间的分布本身也是数据。

要检验标准，就拿一群人比，不拿一个人比。

反过来，对心理学有什么用

心理学家现在开始用语言模型给回答编码、给材料打分。你本来就用一致程度来检验人类评分者；也请把他们之间的差异留下来。在模型替你编码或打分之前，先拿一群人的分布来检验它，而不是拿一份标准答案。讲者的视频数据（讲座里没有展示）说明了原因。在五个人分歧最大的视频上，六个模型的得分都更低。模型之间也更像了：一段视频在六个模型里的排名有多分散，在人们最一致的视频上是 0.577，在分歧最大的 169 段视频上是 0.444，小了将近四分之一。人越分散，模型反而越靠拢。数据也可以反过来用：几千段视频、每段五种读法，能看出人对一件事的解读在哪里、怎样不同。

重点必读

先读这五篇。下面每篇都说明做了什么、发现了什么、对这一部分的问题意味着什么，以及它没有表明什么；方法的细节和数据在哪里，见各自的卡片。

1. 人会从移动的图形里读出意图

Heider & Simmel, 1944, *American Journal of Psychology*

做了什么。一段约两分半钟的影片显示三个几何图形在一个带门的长方形内外移动。三组女大学生共 114 人，各看了两遍：一组只被要求写下发生了什么，一组被要求把这些运动解读为人的行动，一组看的是倒放的影片。

发现了什么。几乎每个被试都把影片描述为有生命的存在的行动，大多是人的行动。有些解读几乎完全一致：无论正放还是倒放，每个被试都看到图形在推门或拉门。对动机和原因的解读差异大得多，倒放影片尤其如此。

对这一部分意味着什么。这是讲座里运动图形背后的经典研究：观察者在动作上一致，在意义上分歧。描述孩子从平衡车上摔下来的五个人，显出的也是这种“看到的”与“推断的”之分；第 4 篇则在情绪评分里看到了它。一群人的分布应当放进参照里，而分布在推断的部分最宽。

它没有表明什么。被试是 1940 年代的 114 名女大学生，研究报告的是描述及其主题，而不是现代的一致性统计量。

2. 聊天模型的训练建立在人的比较之上

Ouyang et al., 2022, *NeurIPS*

做了什么。标注员（也就是心理学说的评分者）为一组提示词写出期望的回答作为示范，再用这些示范对 GPT-3 做微调，也就是拿这些例子把它再训练一下。随后，标注员给同一提示词的多个输出排序。这些排序用来训练一个奖励模型，也就是给每个回答打一个分数的打分模型。再训练语言模型去提高这个分数，这种方法叫基于人类反馈的强化学习（RLHF）。由此得到的 InstructGPT 模型，用询问人们更喜欢哪些输出的方式来评估。

发现了什么。在作者的提示词上，人们更喜欢 13 亿参数的 InstructGPT 模型，而不是 1750 亿参数的 GPT-3，后者的参数是前者的一百多倍（参数是模型在学习中调整的那些数值）。制作训练数据的标注员彼此一致的比例约为 73%（72.6 ± 1.5%）。

对这一部分意味着什么。这是讲座里 AI 领域的经典工作：当今聊天模型背后的参照是一群做比较的人，而他们大约四分之一的时候意见不一致。训练最后只剩奖励模型给的一个分数，所以他们之间的分布没有留下来。用谁的判断、怎样处理他们的分歧，是一个测量问题。

它没有表明什么。模型对齐的（也就是被训练去遵循的）是一个特定的群体：作者的标注员，他们大多讲英语，生活在美国或东南亚；模型还对齐了研究者自己写的指导语。它对齐的并不是一般意义上的人。

3. 每张图约五十人：CIFAR-10H

Peterson et al., 2019, *ICCV*（CIFAR-10H）

做了什么。CIFAR-10 测试集有十个类别的 10,000 张小图像，每一张都由人做了分类。2,571 名 Amazon Mechanical Turk 上的被试各分类 200 张图像，每 20 个试次插入一次注意力检查。随后拿分类器和得到的标签分布比较，也用这些分布来训练分类器。

发现了什么。511,400 个人类判断，每张图像约 50 个，给出了每张图像的完整标签分布。用常规方式训练的分类器没有表现出类似人的不确定性。用人类标签分布训练，可以缩小这一差距。这样训练出的模型，在越来越不像训练图像的测试图像上表现更好，也更不容易被对抗攻击（故意对图像做细微改动，让模型出错）骗过。

对这一部分意味着什么。讲座里没有展示。它把分歧从噪声变成了数据：同一张图像，在大多数人看来是猫，在一些人看来是狗。它是这一部分的检验最简单的例子，拿一群人而不是一个标签来比，并且表明这种比较会改变模型学到的东西。建议在第 5 篇之前读，第 5 篇梳理了它所属的研究领域。

它没有表明什么。图像很小，十个类别也很简单；单一平台上的众包工作者只是一种特定的人类参照。

4. 四十四位评分者，十四部影片：Emo-FilM

Morgenroth et al., 2025, *Scientific Data*（Emo-FilM）

做了什么。44 名评分者为 14 部短片做了标注，总时长超过两个半小时，共 50 个条目：离散情绪，以及来自评价、动机、运动表达、生理反应和感受的情绪成分。另一组 30 人的样本在功能磁共振成像（functional MRI）扫描期间观看同样的影片，同时记录心率、呼吸和皮肤电活动。

发现了什么。评分的平均评分者间一致性为 0.38：尽管每位评分者看的都是同样的影片，这一水平至多算中等。

对这一部分意味着什么。讲座里没有展示。这是 Heider 和 Simmel 的那种区分在现代情绪评分里的样子：评分者评判感受时，一致性只是中等。给这些影片评定情绪的模型，应当以这一分布为参照来评判，而不是以某一位评分者或平均评分者为参照。正如这一部分悬而未决的问题所说，一致性只有 0.38 时，“与人类标签一致”就不是一个定义清楚的目标。

它没有表明什么。这些数据是为情感神经科学设计的，而且 0.38 是平均值：具体条目和时刻上的一致性可能更高，也可能更低。

5. 人们意见不一时，就从分歧中学习

Uma et al., 2021, *JAIR*

做了什么。这是一篇带有自己实验的综述。它回顾了语言和视觉任务中存在分歧的证据，从词性标注（标出每个词是名词、动词等）这样的客观任务到主观任务；随后，凡是每个条目有多个判断的可用数据集，它都拿来训练最常见的几种方法。

发现了什么。训练方法的排名取决于所选的评估方式，所以即使没有单一的金标准，这一领域也必须就如何评估达成一致。软标签保留选每个答案的人各占多少；金标准标签只保留一个答案。每个条目都有高质量编码者给出的大量判断时，直接用软标签训练，效果好于用合并后的标签乃至金标准标签训练。无论拿一个答案给模型打分（硬评估），还是拿答案的分布给模型打分（软评估），都是如此。否则，在硬评估中，结合金标准标签和软标签通常效果最好。

对这一部分意味着什么。讲座里没有展示。它是进入一个研究领域的入口，这个领域把人与人之间的差异视为信

息；它也是这个领域数据集的地图。它从机器学习这一边回答了这一部分的问题：一个标签或一次多数投票，会掩盖人们之间有多大分歧。建议在第 3 篇之后读。

它没有表明什么。它涵盖截至 2021 年的语言和视觉任务；大语言模型作为评分者是后来的事（见更大的版图）。

它们之间的关系

这几篇文献贯穿着四条主线。

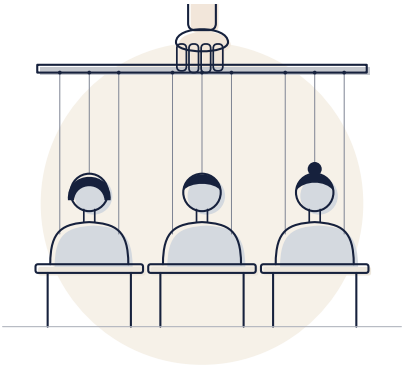
- **一致性是一种测量。**心理学很早就在测量评分者之间有多一致：Cohen's κ 用于两位评分者和类别数据（1960），Krippendorff's α 适用于任意多位评分者和各种数据类型（Hayes & Krippendorff, 2007，doi[12]）。这一部分的习惯是把模型当作又一位评分者，看它和人的一致程度是否达到人与人之间的一致程度。
- **分歧是数据。** Dawid 和 Skene（1979，doi[13]）估计每位观察者的错误率，而不是相信多数人的意见。Aroyo 和 Welty（2015，*Truth is a lie*，doi[14]）认为，很多时候根本不存在一个可以还原的唯一真实标签。CIFAR-10H 为一个图像数据集收集了完整的人类分布，Uma 等则把整个领域梳理到了一起。
- **看到的与推断的。** Heider 和 Simmel 发现，人们对动作的解读几乎一致，对动机的解读却各不相同。Emo-FilM 在现代的情绪评分里看到了同样的模式：评分者评判感受时，一致性只是中等。
- **人的判断成为训练信号，又被取代。** Thurstone 把人在一对对选项之间的选择变成一把尺子（1927，*Psychological Review*，doi[15]）；Bradley 和 Terry 给出了今天的奖励模型所依据的统计模型（1952，*Biometrika*，doi[16]）。从人类偏好中学习（Christiano 等，2017，NeurIPS[17]）成了 InstructGPT 背后的训练方法。如今语言模型被用来代替人当评判者。Zheng 等（2023，*Judging LLM-as-a-judge*，doi[18]）报告 GPT-4 与人类偏好的一致率超过 80%，与人与人之间的一致率相当，同时也报告了位置偏差、冗长偏差和偏向自己的偏差。

悬而未决的问题。如果人们在哪个回答更好这件事上只有 73% 的时候意见一致，在情绪上的一致性只有 0.38，那么“与人类标签一致”就不是一个定义清楚的目标。一个比任何人都更贴近多数意见的模型，可能是把分歧抹平了，而不是匹配了它。报告模型的一致程度时，要放在人与人之间一致程度的范围里，并说明它有没有保留人们之间的分布。

[12] https://doi.org/10.1080/19312450709336664
[13] https://doi.org/10.2307/2346806
[14] https://doi.org/10.1609/aimag.v36i1.2564
[15] https://doi.org/10.1037/h0070288
[16] https://doi.org/10.2307/2334029
[17] https://papers.nips.cc/paper/2017/hash/d5e2c0adad503c91f91df240d0cd4e49-Abstract.html
[18] https://doi.org/10.52202/075280-2020

第 3 部分 · 一个社会：我们造出来的人

它像我们，像到能研究我们吗？检验：**拿真实的人比。**



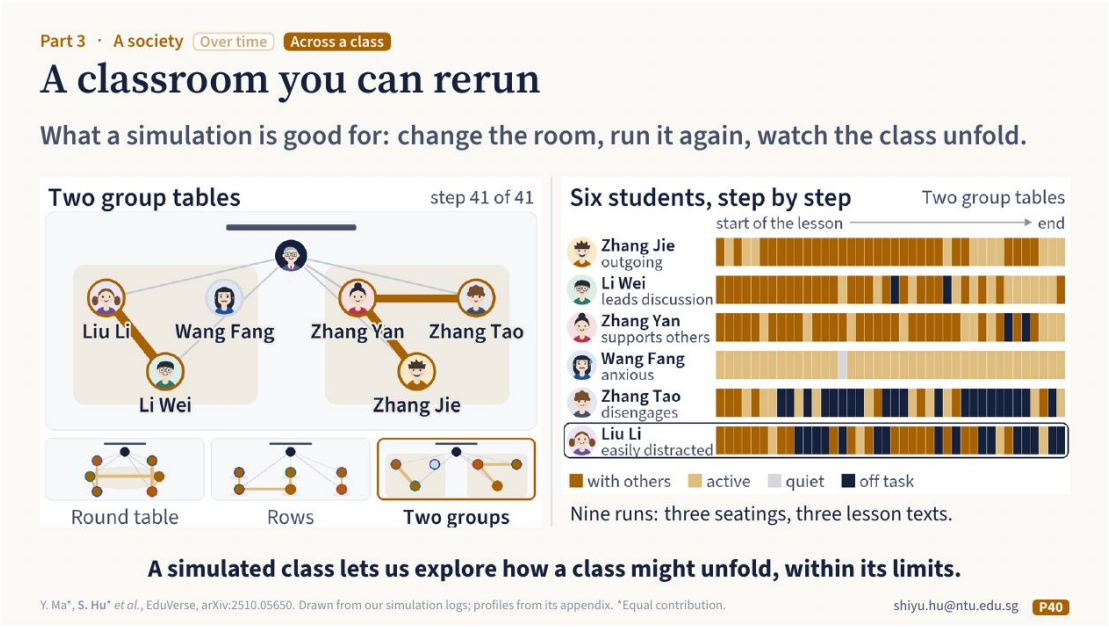
讲座里讲了什么

AI 领域的经典工作。Smallville（斯坦福小镇）起源于一个设计上的需要。在人机交互领域，一个新的线上社区要先找一小群人来试用，可是捣乱和争吵只有在成千上万人加入后才会出现。于是在 2022 年，一个团队让语言模型来扮演用户，包括捣乱的人。给每个用户一个不同的人设，行为才会多样；但每个用户只活在一个时刻，不记得昨天。于是在 2023 年，同一个团队给智能体加上了记忆：这就是 Smallville，二十五个有记忆、会反思、会做计划的智能体。它获得了人机交互顶级会议 UIST 2023 的最佳论文，已被引用九千多次。拿掉这些部分，人们就觉得智能体没那么可信。一个派对邀请随后在镇上传开了：邀请了十几个，来了五个，它们之间的对话并不是写好的。这是很大的一步，但也有局限：智能体很少说“不”，说话太正式，还会走进有人的卫生间；作者提醒，它们不应该取代真实的人。看起来真实，还不等于真实。再后来，这个团队根据真实的人构建智能体：访谈了 1,052 个人，每人两小时，为每个人造了一个数字分身。要检验一个人的复制品，就拿它和同一个人、测两次的结果来比：隔两周再答一次，人和自己之前的回答约 80% 相同，这就是上限；数字分身约三分之二相同（65.7%），相当于上限的 0.83。

心理学早就知道的。心理学用五个宽泛的特质来描述人格，即大五人格（Goldberg, 1990，doi[19]）。讲者团队给每个虚拟学生一种大五人格，讲座从两个方向拿它们和真实的人比：在时间上，从一句回答到一整节课；在一个班里，从一个学生到很多个学生。讲座里没有展示、但出自同一个想法的是：人设是实验者设定的条件，所以心理学把它当作一种操纵。设定它，测量它，再检验它是否改变了它所说的那个特质，并且只改变了这个特质。另一个实验室做过这样一次检验（第 5 篇）：每个特质单独设定，从低到高，结果主要是被设定的那个特质在变。所以这个检验可以通过，但要在你自己用的模型上做。

讲者团队做了什么。以人为参照做虚拟学生。造一个虚拟学生有两条路。容易的一条，是通过 API 给闭源模型一个人设；但对话一长，人设就会漂移：有研究发现，大约八轮对话之内就会明显偏离（Li et al., 2024，*COLM*，arXiv[20]），一个害羞的学生会慢慢变回模型本来的样子，一个乐于助人的专家。之后的每一个检验，问的都是同一件事：它还是我们设定的那个学生吗？所以团队走了另一条路，微调一个小的开源模型，让人设是学进去的，而不只是告诉它的。在第一项研究 EduEval 里，一个模型从真实的课堂、教案和课本出发，为每种大五人格人设写出课堂上的回答。老师修改这些回答，他们的修改又成了后面各批的样例。然后，用这些材料为每种人设训练一个额外的小模块；基础模型保持不变。先看时间上的第一步，一轮：十位有教学经验的评分者做了盲评，训练之后，这些回答和真实学生的回答差不多一样被判为真实。回答看起来真实，不等于背后有一个心智。可漂移是随着时间出现的，所以团队逐轮跟着每个学生，看完一整节课：十位实习老师各教五个虚拟学生，共 50 场、1,288 轮。人设大体保持住了，但有一种类型，即设定为粗心（低尽责性）的学生，变化很大；这是漂移，还是真实学生本来也会这样变，需要真实学生来判断。再看一个班里，从一个智能体到很多个：在模拟班级 EduVerse 里，一位老师和六个学生，每个学生都有自己的人设，都对老师、教室和身边的同学做出反应。每个学生都保持着自己的样子：外向的学生积极、情绪正面，焦虑的学生安静、情绪负面。但不总是按我们设定的那样：她的人物档案说她会逐渐参与，在课上她却很少参与。这是一个中性的结果：各不相同，也符合人设，但不总是像设计的那样。模拟班级还可以重跑：三种座次、三篇课文，共九次运行，谁和谁说话就变了。它不能告诉我们真实的学生会怎样，但能让我们在它的边界之内，探索一个班可能怎样展开。

[19] https://doi.org/10.1037/0022-3514.59.6.1216
[20] https://arxiv.org/abs/2402.10962



讲座第 *40* 页：一间能重来的教室。

背后的问题

它像我们，像到能研究我们吗？够用来预演一项研究，不能取代研究里的人，前提是从真实的人出发，并且每一步都检验。表现得像某一类人，并不等于就是那一类人。人设是你设定的条件，所以需要操纵检验：它有没有改变它所说的那个特质，是否只改变了这个特质，在所有意思相同的措辞下是否都如此？盲评只能说明回答看起来像人，不能说明背后有一个心智。模拟要拿真实的人来比，而且在主张所针对的层面上比：一个人、一个群体，还是一整个班级。

要检验模拟，就拿真实的人比。

反过来，对心理学有什么用

讲座的方向在这里反了过来。前半程（行为分析）是心理学帮我们检验 AI；从这里开始（角色模拟），是 AI 帮我们研究人。检验过的模拟，是心理学和社会科学的新工具：

- **随叫随到的、各不相同的被试。**在研究交到真人手上之前，先让模拟的人预演一遍：先试材料、指导语和实验设计。
- **能重来的课堂。**同样的学生、同样的一节课，换个座次或换一个学生，一遍遍重来：这是任何真实学校都做不到的。先在模拟里试，再到真人身上确认。
- **怎样检验它。**从真实的人出发；拿同一个人、测两次的结果来检验一个模拟的人；跨时间跟着它，而不只看一句回答；比较群体的分布，而不只是平均数；留意会漂移的人设，以及像 Smallville 里那样很少说“不”的智能体。

重点必读

先读这五篇。下面每篇都说明做了什么、发现了什么、对这一部分的问题意味着什么，以及它没有表明什么；方法的细节和数据在哪里，见各自的卡片。

1. 社会拟像：开张之前就住满人的社区

Park et al., 2022, *UIST*

做了什么。设计者用自然语言描述一个新的线上社区：它的目标、规则，以及几个成员人设。一连串发给 GPT-3 的提示词，每一条都接着上一条的回答往下写，把这些描述扩展成数千个成员，由他们发帖和回复，其中也包括反社会行为。作者只用 50 个真实 subreddit（Reddit 上的讨论组）的目标和规则重新生成讨论，请 200 名参与者从一真一假的成对对话中挑出真实的那段。

发现了什么。参与者平均认错了 41%（SD = 10）的配对；随机猜测是 50%。众包工作者写的对话更容易被认出来（32%）。

对这一部分意味着什么。 Smallville 正是从这里来的：设计者需要随叫随到的、各不相同的测试用户，这也是这一部分所说的、检验过的模拟能回馈的第一样东西。它还确立了评判模拟的人的一个早期标准：人能否分辨生成的行为和真实的行为？第 2、3 篇展示了同一个团队如何从这里走向与真实的人相比较。

它没有表明什么。分辨真假检验的是像不像，而不是准不准：一段讨论可以看起来很真，却与这个社区实际会怎样发展并不相符。评估用的是 Reddit、英语、美国的参与者，以及 2020 年还没有经过指令训练的 GPT-3 模型。

2. 二十五个生成式智能体组成的小镇

Park et al., 2023, *UIST*

做了什么。每个智能体都用自然语言记录自己的经历，把这些记忆凝练成更高层次的反思，并检索它们来规划下一步做什么。二十五个智能体生活在一个受 *The Sims* 启发的模拟小镇里，像一个游戏世界。一百个人评价了这些智能体的可信度（像不像真人）。作者还做了几个删减版本，把各个部分依次拿掉：先去掉反思，再连规划也去掉，最后连记忆也去掉。

发现了什么。智能体产生了可信的个体行为和涌现的社会行为。用户只指定了一个想法，即某个智能体想办一场情人节派对，智能体们便传播邀请、相互邀约，并在正确的时间一同到场。每个部分都让智能体更可信。完整的智能体得 29.9 分；去掉反思，26.9；去掉反思和规划，25.6；记忆、反思、规划都没有，21.2。扮演同样角色的真人得 23 分，低于完整的智能体。

对这一部分意味着什么。这就是讲座里 Smallville 背后的研究，也正是它让用语言模型模拟人成为一个领域。它的评判标准是可信度，而可信还不等于行为像真实的人。正如这一部分所指出的，它的智能体还很少说“不”，这是任何模拟都要留意的迹象。

它没有表明什么。研究表明，这些行为在观察者看来像人；但它没有把智能体与真实小镇里真实的人的行为相比较。第 3 篇是同一个团队对这个缺口的回应。

3. 为 1,052 个人各造一个智能体

Park et al., arXiv:2411.10109

做了什么。研究者按分层抽样找了 1,052 名美国人，每人先和一个 AI 访谈员谈两小时，再做 General Social Survey（GSS）的核心部分、Big Five Inventory、经济博弈和已发表的实验，隔两周再做一遍。基于 GPT-4o 的智能体拿到的是这个人的访谈、问卷回答或两者都有，再和只拿到人口学信息的智能体比。标准化准确率的算法是：智能体答得和本人一样的比例，除以本人第二次答得和第一次一样的比例。

发现了什么。在没有提供给智能体的 GSS 题目上，访谈智能体给出与本人相同答案的比例是 65.67%；人重复自己答案的比例是 79.53%：标准化准确率为 0.83（当前版本 v3）。只用人口学信息的为 0.74。

对这一部分意味着什么。这是讲座里从虚构居民走到真实的人的那一步。评判一个模拟的人，不是像第 2 篇那样看它像不像人，而是拿同一个人、测两次的结果来对照。人自己两周内的一致程度成了上限：这就是这一部分的检验，在一个人身上做到了精确。

它没有表明什么。与个人相符不等于重现了一个样本中各种态度之间的关联。在经济博弈中，没有哪一类智能体显著好于只用人口学信息的智能体；在实验中，智能体得出的效应量大于人的。

4. 由一而多：硅样本

Argyle et al., 2023, *Political Analysis*

做了什么。作者从美国大型调查的真实参与者那里取来数千份社会人口学背景故事，交给 GPT-3，让它以每个人的身份作答（AI 领域叫作给模型设定条件）。这些“硅样本”回答同样的调查问题，答案再和背景相同的真实参与者比。

发现了什么。 GPT-3 中的偏差不是一种单一、均匀的属性，而是细粒度的，并与人口学特征相关，因此给它合适的背景故事，模型就能重现许多人类子群体的回答分布。作者称之为算法保真度（*algorithmic fidelity*），并认为具备足够算法保真度的模型可以成为研究人与社会的工具。

对这一部分意味着什么。这里与真实的人的比较是在群体层面上做的，而不是像第 3 篇那样在一个人的层面上。它比较的是回答分布，这正合这一部分的建议：比较群体的分布，而不只是平均数。讲座里没有展示，但它说明的正是讲座的观点：模拟被试可以为研究做预测试，不能取代样本。

它没有表明什么。对照的只是美国调查受访者在所研究问题上的回答。后来的研究发现，硅样本可能把某些身份群体描绘错，或抹平群体内部的差异，合成的调查数据也可能误导人（见它们之间的关系）。

5. 用心理测量学的方法测量和塑造模型的人格

Serapio-García et al., 2025, *Nature Machine Intelligence*

做了什么。研究者用多种提示方式（指令的不同措辞和框架），让 18 个语言模型作答成熟的人格量表，再像对人类测验那样，检查这些得分的信度，以及相对于其他测量的效度。反过来，用指令把特质设定到目标水平，作者再检查随后生成的文本是否表达了这些水平。

发现了什么。对某些模型而言，在特定的提示方式下，测量是可靠且有效的，对更大的模型以及经过进一步训练以遵循指令的模型更明显。模型的输出可以被塑造，以模仿特定的人类人格画像。

对这一部分意味着什么。人设是有人设定的条件，所以需要操纵检验：它有没有改变它所说的那个特质，是否只改变了这个特质，在所有意思相同的措辞下是否都如此？这项研究展示了完整运用心理测量学时，这样的检验是什么样子。讲座里没有展示，但这正是人设需要的检验：每个特质单独设定，从低到高，结果主要是被设定的那个特质在变。

它没有表明什么。问卷是第一步检验，这项研究把它完整地做了一遍。一个模型被要求外向之后，问卷得分显示外向，可能只是在执行指令，而不是具有这种特质；所以人设没有点名的行为是更有力的检验。

它们之间的关系

这几篇文献贯穿着四条主线。

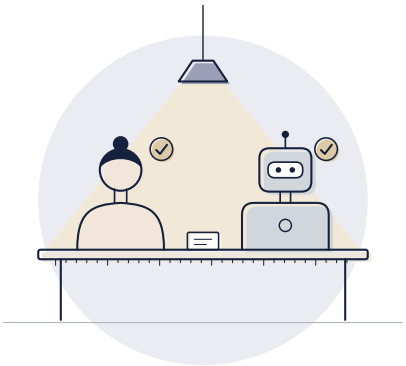
- **从试用者到小镇，再到真实的人。** Park 等先让模型扮演一个还不存在的线上社区的用户（2022），再造出一个智能体小镇（2023），之后又为 1,052 位真人各造一个智能体，拿同一个人、测两次的结果来检验（2024）。这条线延续了一个更早的传统，即用基于智能体的模型研究社会：从 Schelling 的隔离模型（1971，doi[21]）到 Epstein 的生成式社会科学（1999，doi[22]1099-0526(199905/06)4:5%3C41::aid-cplx9%3E3.0.co;2-f)），只是如今的智能体会说话了。
- **人设是一种操纵。** Serapio-García 等把模型的人格当作可以用心理测量标准来测量、用指令来塑造的东西。因此人设是实验者设定的一个条件。和任何操纵一样，它需要检验：它有没有改变它所说的那个特质，是否只改变了这个特质，在所有意思相同的措辞下是否都如此？
- **模拟样本和它的批评者。** Argyle 等把真实受访者的背景交给模型，生成硅样本。后来的研究发现，这类样本可能误导人（Bisbee 等，2024，doi[23]），还可能歪曲并抹平身份群体（Wang 等，2025，doi[24]）。
- **经典范式成为检验智能体的测试。** Weng 等把 Asch 的从众实验设计（1955，doi[25]）连同它的控制条件一起，搬到了语言模型智能体身上；讲座里没有展示。

悬而未决的问题。表现得像某一类人，并不等于就是那一类人。一个模拟被试之所以这样表现，部分是因为有人给了它这样的人设。要了解真实的人，先要检验人设是否起到了应有的作用，再在主张所针对的层面上，比如个人、群体或一整个课堂，把模拟与真实的人相比较。打乱资料、盲评这类控制有帮助，但它们说明的是输出看起来怎样，而不是背后有什么。

[21] https://doi.org/10.1080/0022250x.1971.9989794
[22] https://doi.org/10.1002/(sici
[23] https://doi.org/10.1017/pan.2024.5
[24] https://doi.org/10.1038/s42256-025-00986-z
[25] https://doi.org/10.1038/scientificamerican1155-31

第 4 部分 · 在你自己的研究里用 AI

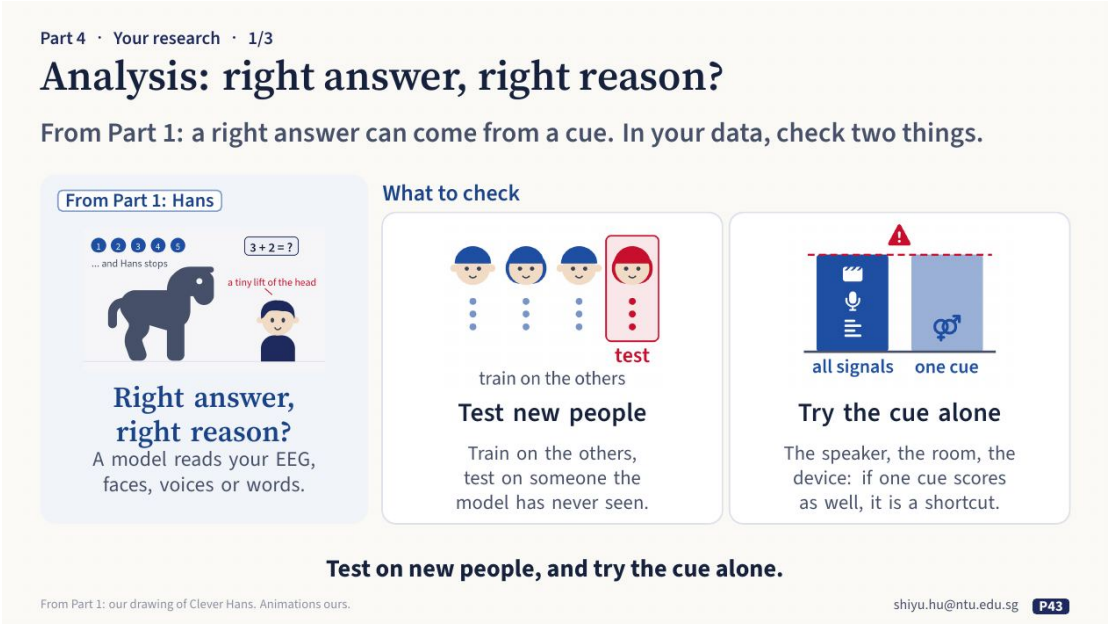
你可以怎样用它？先检验，再使用。



讲座里讲了什么

讲座的最后一部分，把前三部分的检验带进你自己的研究，副标题是“两种用法：分析你的数据，模拟人”。前面每个部分对应一页，每页给出两个检验。

分析：答对了，理由也对吗？ 来自第 1 部分：正确答案可能来自一个线索，就像汉斯读的是提问者的头，图像模型读的是照片上的标签。现在，模型读的是你的脑电、表情、声音或文字。要检验两件事。拿新的人来测：用其他所有人训练，拿一个模型从没见过的人来测试；如果同一个人既在训练数据里又在测试数据里，分数就会好得不真实。只用一个线索试试：说话的人、房间、设备；如果一个线索的分数和你的模型一样高，那就是一条捷径。（一个讲座里没有展示的例子：在一个公开数据集上，只预测一个人的性别，就和顶尖的 AI 谎言检测器做得差不多；Mambreyan et al., 2022，接受版本[26]。）



讲座第 *43* 页：分析，答对了，理由也对吗？

测量：谁的标准？ 来自第 2 部分：人与人会有分歧，就像五个人对同一次摔倒有五种读法。你的标签来自评分者或量表：情绪、幸福感。保留每一个评分者：拿模型和你所有的评分者比，而不是和他们的平均比。而且，他们之间的一致程度就是上限：如果你的评分者彼此只能一致到这个程度，就别指望模型更好，就像同一个人问两次，是数字分身的上限一样。用你的量表训练出来的模型，学到的是量表，而不是量表背后的东西，所以要像检验任何一个新测量一样，检验它的效度。

模拟：像我们吗？ 来自第 3 部分：智能体可以看起来很真实，却仍然会漂移。模型扮演你的被试，或者作为互动伙伴和被试对话，比如陪伴者、辅导者。看整个分布：拿它和真实的人比回答的范围，而不只是平均，因为模拟出来的人往往彼此太像（一项讲座里没有展示的研究发现，模拟的调查回答平均数接近真人，差异却太小；Bisbee et al., 2024，doi[27]）。跨时间检验：第一次见面告诉它一件事，第三次再问它。还要固定它的决策，只让措

[26] https://www.repository.cam.ac.uk/handle/1810/338298
[27] https://doi.org/10.1017/pan.2024.5

辞变化：这就是心理学早就有的干预保真度（treatment fidelity）。

背后的问题

你可以怎样用它？先检验，再使用。读你数据的模型、从你的标签里学习的模型，或者扮演一个人的模型，都是你还没有验证过的测量工具。讲座的三页各自带回前面的一个问题：答对了，理由也对吗？（拿新的人来测，再只用一个线索试试）；它遵循谁的标准？（保留每一个评分者，他们的一致程度就是上限）；它像我们，像到能研究我们吗？（看整个分布，也跨时间检验）。记下模型、版本、日期、完整的提示词、设置和运行次数，让别人能够核查：模型会变，措辞的一点改动也可能改变答案。

先检验，再使用：拿新的人来测，只用一个线索试试；保留每一个评分者；看整个分布，也跨时间检验。

反过来，对心理学有什么用

在这里，讲座用心理学自己的话，把它的检验交还给心理学。研究里的模型只是又一个需要验证的工具，而验证本来就是心理学熟悉的工作：留出不参加训练的被试，为可疑的线索设控制条件，评分者之间的一致性和测量的效度，和真实样本比较，以及干预保真度。这样用，模型可以让某些步骤更省力，比如做第一轮编码，或者预演一个设计，而结论仍然要靠人来支撑。

第 4 部分和总结之后，讲座以讲者自己的看法收尾，题目是“为什么心理学和人文学科现在更重要”（为什么是现在）。模型跑得很快，每个说法都还需要核查。造东西变便宜了，判断变稀缺了。所以：比模型活得久，问问如果模型再强十倍，这件事还重要吗；让 AI 去做，你来判断，初稿自己写；找到你自己的交叉点，从你的领域最擅长提出的问题出发，再把 AI 带进来，比如问一问：和 AI 说话，是增加了人与人的接触，还是取代了它？当造东西变得便宜，判断才是真正的工作，而这一直是心理学和人文学科的本职。

重点必读

先读这五篇。下面每篇都说明做了什么、发现了什么、对这一部分的问题意味着什么，以及它没有表明什么；方法的细节和数据在哪里，见各自的卡片。

1. 语言模型能为心理学做什么，不能做什么

Demszky et al., 2023, *Nature Reviews Psychology*

做了什么。这是一篇由心理学家和计算机科学家合写的 Perspective（观点）文章。它解释了语言模型如何产生类似人类的语言，却不像人那样思考或感受，随后综述了语言模型在心理测量、实验和实践中的用途。

发现了什么。作者认为，模型可能推动这三方面，但对许多最具变革性的应用还没有准备好。他们考察了四个重大担忧，并建议做三项投入：由领域发起的“keystone”（基石）数据集，更标准化的基准，以及共享的计算与分析基础设施。

对这一部分意味着什么。讲座里没有展示。它是专为心理学家写的、关于这一主题最全面的单篇地图，很适合第一个读：它涵盖了这一部分的三种用法（模型当编码者、测量文本中的构念、模拟被试），以及随之而来的担忧。其余四篇各自细看一种用法。

它没有表明什么。它写于 2023 年；此后模型已经变了，不过这些担忧并没有消失。它是综述和论证，没有报告新的数据。

2. 让模型当编码者：有前景，但需要验证

Gilardi et al., 2023, *PNAS*，与 Reiss, 2023 一起读

做了什么。 Gilardi 及其同事在推文和新闻文章（n = 6,183）的四类编码任务上，把不给示例（“zero-shot”，零样本）的 ChatGPT 与众包工作者和受过训练的标注者（心理学里叫编码者）相比较。Reiss 在一个真实任务上（把网站文本分为新闻和非新闻）重复输入完全相同的内容，并改变设置和提示词的措辞。

发现了什么。 ChatGPT 的零样本准确率平均比众包工作者高约 25 个百分点；在所有任务上，它的编码者间一致性都高于众包工作者和受过训练的标注者；成本约为众包的三十分之一。Reiss 发现，措辞有微小变化，或者只是重复一次，输出都可能改变；把多次重复的结果合并起来会有帮助。

对这一部分意味着什么。讲座里没有展示，但它是把讲座的测量检验用在编码上：拿模型编码者和你的人工编码者在同样的材料上比，就像心理学检验任何编码者那样。Reiss 说明，提示词的措辞一变，甚至只是再运行一次，输出都可能改变。第 4 篇接着讨论用上这些标签之后的问题。

它没有表明什么。两项研究都只涵盖某一时刻的特定任务、语言和模型版本；一种编码方案上的结果不会自动迁移到另一种方案。

3. 用十二种语言做心理学文本分析

Rathje et al., 2024, *PNAS*

做了什么。研究者给三个版本的 GPT 简单的提示，例如“is this text negative?”（这段文本是负面的吗?），让它们在 47,925 条已由人标注过的推文和新闻标题中检测情感倾向、情绪、冒犯性和道德基础，涵盖 12 种语言。它们的回答与人类标注、词典方法和微调过的模型（针对某一任务进一步训练过的模型）相比较。

发现了什么。 GPT 与人类标注者的一致性（r = 0.59 到 0.77）远高于英语词典分析（r = 0.20 到 0.30），并接近、有时还超过了几个顶尖的微调过的模型。新版本表现更好，在使用人数较少的语言上尤其明显。

对这一部分意味着什么。讲座里没有展示。测量文本中的构念，是心理学家最可能对模型做的日常用途；这里用熟悉的方式检验它：对照人的判断和这个领域已有的方法。由于结果随版本而变，它也说明了为什么必须记下版本。

它没有表明什么。这里的“准确”指与现有标注一致，因此模型的效度最多与这些标注相当。0.6 到 0.8 的相关仍然给特定类型文本上的系统差异留下了空间。

4. 用 AI 标签加少量人工标签得出有效结论

Angelopoulos et al., 2023, *Science*

做了什么。这是一个统计框架，不是一项实验。用人标注的少量条目衡量模型的预测偏离多远，再把这一校正应用到由模型标注的大量条目所得的估计上。它为均值、分位数以及线性回归和逻辑回归系数给出置信区间。

发现了什么。这些区间可以证明是有效的，而且对提供预测的系统不作任何假设；预测越准确，区间越窄。演示数据来自六个领域，从蛋白质组学到生态学。

对这一部分意味着什么。讲座里没有展示。它回答了第 2 篇之后的问题：如果模型编码了大部分数据，还能得出什么结论，又需要多少人工标签？它把这一部分对编码者的结论，即每次都要对照人来验证，纳入了估计本身。

它没有表明什么。人工标注的条目必须是从与模型标注条目相同的总体中抽取的随机样本。该方法在平均意义上校正模型的误差；它不会让有偏模型的标签逐条变得有效。

5. 在做实验之前预测它的结果

Ashokkumar et al., 2026, *Nature*

做了什么。作者提示模型模拟有代表性的美国样本会如何回应 70 项预注册的美国调查实验（469 个效应，119,330 名参与者），并比较不同条件下的模拟回答。15 项大型研究（megastudies，606 个效应）作为进一步的检验。

发现了什么。 GPT-4 的预测与实际效应高度相关，准确度与人们汇总后的预测相近，对于在它的训练数据收集完毕（即训练截止日期）之前没有发表或公开的研究也是如此。这些预测系统性地高估了效应量。在大型研究上，相关性较低，但与汇总后的专家预测者相当。

对这一部分意味着什么。讲座里没有展示，但它印证了讲座的观点：模拟被试可以用来预测试一项研究，但不能取代样本。它支持一种谨慎的用法：预测效应的方向，用来挑选研究、做预实验或排定研究的优先顺序。它承接第 3 部分的硅样本；这里的检验与第 3 部分相同：拿真实的人比。

它没有表明什么。这些实验都是美国的调查实验。在许多效应上相关良好，并不能让任何单个预测变得可靠；如果用高估的效应量代替真人预实验来做功效分析，会产生误导。

它们之间的关系

这几篇文献贯穿着三条主线。

- **模型当编码者。**心理学早就知道怎样检验一位编码者：看他和其他编码者在同样材料上的一致性。Gilardi 等发现模型比众包工作者更准确、更一致。Reiss 发现，提示词的措辞一变，甚至只是再运行一次，它的输出都可能改变。Pangakis 和 Wolken（2025，*Keeping humans in the loop: Human-centered automated annotation with generative AI*，ICWSM，doi[28]）得出结论：每次都要对照人来验证。预测驱动推断和基于设计的监督学习（Egami 等，2023，doi[29]）则说明了怎样从模型标签加一组人工标签中得出有效的结论。
- **测量文本中的构念。** Rathje 等把模型与心理学家长期使用的词典方法相比较，发现模型在多种语言中都更接近人的判断。
- **模拟被试用于预测试。**硅样本（第 3 部分的重点必读）提出了这个想法；Ashokkumar 等在 70 个真实实验上检验它，发现方向预测得好，效应大小却被夸大。Crockett 和 Messeri（2026，*AI surrogates and illusions of*

[28] https://doi.org/10.1609/icwsm.v19i1.35883
[29] https://doi.org/10.52202/075280-3000

generalizability in cognitive science，doi[30]）以及 Gao 等（2025，*Take caution in using LLMs as human surrogates*，doi[31]）阐明了为什么模拟不应该取代样本。

Demszky 等涵盖了这三种用法，以及随之而来的顾虑。

悬而未决的问题。在研究里用一个模型，它就成了你的测量工具之一。前三部分的检验对它和对任何工具一样适用：比错误，不只比分数（它错在哪里？提示词的一点小改动会不会改变答案?）；拿一群人比，不拿一个人比（它是否对照不止一个人做过验证?）；以及拿真实的人比（用作预测试，而不是当作样本）。记下模型、版本、日期、完整的提示词、设置和运行次数，让别人能够核查。

[30] https://doi.org/10.1016/j.tics.2025.09.012
[31] https://doi.org/10.1073/pnas.2501660122

词典

每个术语一行；完整的词条和出处见 docs/glossary.zh.md。

第 1 部分 · 一个人：答对了，理由也对吗？

- **线索（Cue）：** 输入中任何一个人或模型可以借以得出答案的特征，比如物体的形状、它的纹理、角落里的水印，或者问题的措辞。两个线索在普通题目上可能指向同一个答案，在不寻常的题目上却指向不同的答案。
- **线索冲突（Cue conflict）：** 一种刻意构造的刺激，让两个线索指向不同的答案，比如一张有猫的形状、大象皮纹理的图片。答案显示了哪个线索胜出。
- **形状偏好（Shape bias）：** 在线索冲突图片上，跟着形状而不是纹理做出的判断所占的比例。人有很强的形状偏好；用 ImageNet（一个大型的带标签照片集）训练的网络则偏好纹理。
- **错误一致性（Error consistency）：** 两个决策者错在同样题目上的频率，超出各自正确率按偶然所能产生的程度。计算方法是逐个试次地对对错计算 Cohen's κ。
- **Cohen's kappa：** 用于两位评分者把题目分到各个类别时的一致性统计量。它从观察到的一致性中扣除了按偶然预期的一致性。$\kappa = 0$ 是偶然水平，$\kappa = 1$ 是完全一致。
- **聪明的汉斯效应（Clever Hans effect）：** 由一个非预期的线索产生的正确答案。名字来自聪明的汉斯，一匹看起来会数数和计算的马，实际上它是在对提问者头部极其细微、无意的动作作出反应。Oskar Pfungst 在 1904 年通过去掉这个线索证明了这一点。
- **捷径学习（Shortcut learning）：** 学到的决策规则在标准基准（大家共用的测试题集）上表现良好，却无法迁移到更有挑战的测试条件，比如真实世界的场景。这里沿用 Geirhos et al.（2020）的定义。
- **人类基线（Human baseline）：** 人在与模型相同的题目、相同的条件下表现如何。它是判断“人类水平”的参照。
- **分布外数据（Out-of-distribution data）：** 与训练数据有系统差异的测试题目，比如对一个用照片训练的模型来说，加了噪声的、风格化的或只有边缘的图片。常简称为 OOD。
- **心理物理学（Psychophysics）：** 测量刺激的物理属性如何与知觉相联系的方法，使用受控的刺激、大量的试次和严格的呈现条件。
- **解释方法（Explanation method）：** 显示模型做决策时依赖了输入的哪些部分的技术，常常是叠在图像上的一张热图。也叫相关性方法或归因方法。

第 2 部分 · 一群人：它遵循谁的标准？

- **参照（Reference）：** 模型拿来比较的人类数据：每题一个标签、一次多数投票、几位评分者，或者人们回答的完整分布。
- **评分者信度（Inter-rater reliability）：** 独立的评分者评判同样的题目时，彼此一致的程度。
- **Krippendorff's alpha：** 一个适用于任意多位评分者、适用于名义、顺序、等距或等比数据、也适用于有缺失评分的数据的一致性系数。$\alpha = 1$ 是完全一致，$\alpha = 0$ 是偶然水平。
- **金标准标签与多数投票（Gold label and majority vote）：** 金标准标签是给一道题指定的唯一“正确”答案。多数投票是几位评分者中最常见的答案。AI 里的大多数数据集存的是这两者之一。
- **标签分布（Label distribution）：** 一道题上选择每个答案的人所占的比例，比如 70% 选猫、30% 选狗。软标签是把这个分布当作训练目标，而不是只用一个答案。
- **人类标注差异（Human label variation）：** 人们对同一道题会给出不同而又合理的答案这一事实，以及把它当作研究对象、而不是当作误差的研究。
- **视角主义（Perspectivism）：** 一种观点：对许多任务来说，并不存在唯一的真实答案，不同评分者群体的视角应当被保留下来并加以建模。
- **看到的与推断的（Seen and inferred）：** 输入中可以观察到的东西（比如一个动作或一件事）与被解读进去的东西（比如一种意图或一种感受）之间的区分。人们通常在前者上比在后者上更一致。
- **评分者模型（Rater model）：** 描述每位评分者如何产生标签的统计模型，比如每位评分者的错误率，用来合并许多不完美的评分。
- **基于人类反馈的学习（Learning from human feedback）：** 用人对模型输出的判断来训练模型，通常的做法是让人比较或排序答案，用这些比较训练一个奖励模型，再调整模型使它在奖励模型上得分高。
- **大语言模型当评判者（LLM as a judge）：** 用大语言模型代替人类评判者来给答案打分或比较答案。

第 3 部分 · 一个社会：像到能研究我们吗？

- **机器演人（Machine playing people）：** 让模型扮演人：一个虚拟学生、一个模拟的班级或小镇、一群智能体，或者一项研究里的被试。有时它扮演某个人身边的人，比如受训老师面对的那个班级；有时它代替被试作答。无论哪种情况，得出的结论都是关于真实的人如何行为的。
- **人设（Persona）：** 在指令中给模型的一段描述，说明它应该是谁：特质、背景、观点或角色。
- **操纵检验（Manipulation check）：** 检验一项操纵是否起到了应有的作用。对人设来说，讲座里的检验是：它有没有改变它点名的那个特质，而且主要只改变这个特质？意思相同的措辞，也应该给出相同的结果。
- **硅样本（Silicon sample）：** 以真实调查受访者的背景为条件，让语言模型生成的一组回答，用来代替人类样本。这个术语来自 Argyle et al.（2023）。
- **算法保真度（Algorithmic fidelity）：** 一个经过适当条件设定的模型，在多大程度上能复现特定人类子群体的回答分布。这个术语来自 Argyle et al.（2023）。
- **图灵测试（Turing test）：** 图灵的模仿游戏：一位评判者用文字同一台机器和一个人交谈，说出哪个是哪个。在标准的三方版本中，评判者同时和两者交谈。
- **生成式智能体（Generative agent）：** 一个建立在语言模型之上、带有记忆、反思和规划能力的软件智能体，能随时间产生可信的行为，并与其他智能体互动。
- **从众（Conformity）：** 改变自己的答案去和群体保持一致。Asch 证明，当前面每个人都给出明显错误的答案时，许多人也会跟着给出错误答案。
- **基于智能体的模型（Agent-based model）：** 一种模拟：许多个体智能体遵循行为规则并相互作用，群体层面的模式从个体行为中涌现出来。

第 4 部分 · 在你自己的研究里用 AI

- **AI 编码者（AI coder）：** 用来为研究给材料打标签或编码的语言模型，比如把文本分类、评定情感，或者给开放式回答编码。
- **提示词敏感性（Prompt sensitivity）：** 指令的措辞以本不该有影响的方式改变时，或者同样的输入只是再运行一次时，模型输出发生的变化。
- **预测驱动推断（Prediction-powered inference）：** 一种统计框架，把一大批模型预测和一小批人工标签结合起来，给出有效的置信区间，而不假定模型是正确的。
- **模拟被试（Simulated participant）：** 被提示像研究被试那样作答的语言模型，用来预测试材料、预测结果，或者（有争议地）取代样本。

一起做研究：心理学与 AI 研究

这一页由一位 AI 研究者写给心理学的研究者和学生，写给想和 AI 研究者一起回答讲座那个问题的人：**它看起来很有能力，我们怎么知道它真的具备这种能力？**这个问题，哪一方都无法单独回答。AI 研究有模型、基准（标准的测试题集），以及在大量题目上运行它们的工程能力。心理学有把“看起来能干”和“真的能干”区分开的方法：受控设计、测量与效度、真实的人的样本、信度和伦理。

这一页说明两边各带来什么，两个领域在哪里相遇（讲座的四个问题各对应一处），开始之前要谈妥的事，以及两边最常见的误会。每一处都配有阅读建议和可以借鉴的已发表研究。

两边各带来什么

方面	心理学带来	AI 研究带来
问题	一个构念，以及什么可以算作它的证据	一个模型，以及据说它做得很好的任务
设计	实验范式、控制条件、平衡设计、预注册	模型的使用权限、提示词和设置；在成千上万道题上多次运行
人	样本、招募、知情同意和伦理审批	基准和数据集，常常每题只有一个标签
测量	信度、效度、心理测量	正确率之类的指标，以及逐题的输出
分析	效应量，与人与人之间的分布范围相比较	解释方法、训练和微调（在已有模型上继续训练）、多智能体模拟

两个领域在哪里相遇

1. 答对了，理由也对吗？

第 *1* 部分 · 一个人。检验：比错误，不只比分数。

- **问题。**一个模型在某项任务上的分数和人相近。它是出于同样的理由做到的吗？
- **心理学带来。**任务和题目；你怀疑模型在用的线索；一个把这个线索和你本来想考的线索分开的控制条件；一组在同样条件下接受测试的人。
- **AI 研究带来。**在同样的题目上运行一个或几个模型，并给出逐题输出；对图像模型，还可以给出显示模型看了哪里的解释图。
- **先读。** Geirhos、Meding 和 Wichmann（2020）关于错误一致性的研究；Pfungst（1911）关于聪明的汉斯。
- **可以借鉴的研究。**分数相近，错误不同。

2. 它遵循谁的标准？

第 *2* 部分 · 一群人。检验：拿一群人比，不拿一个人比。

- **问题。**据说一个模型与“人类标签”一致。这是谁的标签？人与人之间又有多一致？
- **心理学带来。**评分设计；评分者如何抽样；评分者信度；把看到的（一个动作）和推断的（一种感受）分开。
- **AI 研究带来。**模型在大量题目上的输出和重复运行；对照人们回答的分布来评测（或训练），而不是对照单一标签。
- **先读。** Heider & Simmel（1944）；Morgenroth 等（2025），Emo-FilM，*Scientific Data*，doi[32]。在 Emo-FilM 中，评分者对逐时刻情绪的一致性只是中等。
- **可以借鉴的研究。**每张图约五十人和四十四位评分者，十四部影片。

3. 它像我们，像到能研究我们吗？

第 *3* 部分 · 一个社会。检验：拿真实的人比。

- **问题。**一个模拟被试，或者一群智能体，表现得像某一类人。人设是否起到了它所说的作用？模拟与真实的人相符吗？
- **AI 研究带来。**人设、智能体和多智能体模拟；多次运行它们，并且用同一条指令的几种措辞。

[32] https://doi.org/10.1038/s41597-025-04803-5

- **心理学带来。**操纵检验；经过验证的问卷和行为测量；可以拿来对照的真实的人的数据；盲评。
- **先读。** Serapio-García 等（2025）；Turing（1950）；Jones 和 Bergen（2026）；Park 等（2023）。
- **可以借鉴的研究。**测量和塑造模型的人格和借助人设的三方图灵测试。

4. 你可以怎样用它?

第 *4* 部分 · 在你自己的研究里用 *AI*。检验：先检验，再使用。

- **问题。**一个模型分析你的数据、从你的标签里学习，或者扮演被试、和被试对话。你还能对人得出什么结论?
- **AI 研究带来。**选择模型并完成设置；每次都用同样的方式运行；保留每一次运行的输出。
- **心理学带来。**用来测试它的新的人，以及针对可疑线索的控制条件；每一个评分者，以及作为上限的他们之间的一致程度；测量的效度；真实的样本和它的分布，模拟的预测试不能取代它；干预保真度。
- **可以借鉴的研究。**让模型当编码者和预测实验的结果。

开始之前要谈妥的事

- **主张**，用一句话写出来，并说明它针对的层面：一个人、一个群体，还是一个社会。
- **数据。**谁提供哪些数据；尽量使用公开数据；在向任何人收集数据之前，先取得伦理审批和知情同意。
- **模型记录。**每个条件都记下模型、版本、日期、完整的提示词、设置和运行次数。
- **什么算通过**，在任何人看到结果之前定下来。
- **谁做什么**，以及署名怎样决定。

两边常见的误会

- **“分数越高，就越像人。”**分数相近可能掩盖了不同的错误；要比较各自错在哪些题上（第 1 部分）。
- **“人类标签就是答案。”**它只是对这道题的一种解读，人们常常意见不一；要拿模型和人与人之间的分布相比较（第 2 部分）。
- **“如果人分辨不出来，它就像人。”**盲评说明的是输出看起来像人，而不是背后有什么（第 3 部分）。
- **“一条提示词就是一次实验。”**提示词的措辞一变，甚至只是再运行一次，模型的输出都可能改变；要换措辞、重复运行，并报告每一次运行（第 4 部分）。
- **“模型是黑箱，所以它的行为没法研究。”**它的行为可以用心理学本来就用在人身上的设计来研究：受控的题目、逐题的数据和操纵检验。
- **“模拟样本可以取代被试。”**模拟样本预测真实效应的方向还不错，却高估了效应的大小；要把它用作预测试，而不是当作样本（第 4 部分）。

从心理学最擅长的地方开始：测量和实验设计。

继续阅读

在仓库里：`resources/reading-path.zh.md`（一步一步的阅读路线），`resources/examples/`（每篇重点必读一张卡片），`resources/students.md`（按心理学方向的阅读清单，英文），`resources/README.md`（按讲座部分，英文），以及 `resources/literature.md`（约 300 篇参考文献，全领域，英文）。

文字与图表：CC BY-NC 4.0。讲座插图：© 2026 Shiyu Hu，保留所有权利。由仓库中的 `docs/handout/make_handout.py zh` 生成。